Визуализация данных с Matplotlib и Seaborn

Подключение библиотек и скриптов

In [1]:
```
import numpy as np
import pandas as pd
```

In [2]:
```
import matplotlib.pyplot as plt
import seaborn as sns
```

In [3]:
```
# Считываем датасет
df = pd.read_csv('bank.csv', sep=';')
df.sample(n=10)
```

Out[3]:

	age	job	marital	education	default	balance	housing	loan	contact	day	m
17100	42	management	divorced	secondary	no	284	no	no	cellular	25	
22678	58	blue-collar	married	unknown	no	9	no	no	cellular	25	
35195	35	technician	married	secondary	no	883	yes	no	cellular	7	
13117	59	retired	divorced	primary	no	830	no	yes	cellular	8	
29034	42	entrepreneur	married	secondary	no	46	no	no	cellular	2	
44256	27	admin.	married	tertiary	no	2855	no	no	cellular	22	
12587	44	blue-collar	married	secondary	no	978	no	no	unknown	3	
5828	31	services	divorced	secondary	no	-274	yes	no	unknown	26	
30224	57	management	married	tertiary	no	297	no	no	cellular	5	
14888	34	blue-collar	married	primary	no	602	yes	no	cellular	16	

Стандартный синтаксис создания графика

In [4]:
```
plt.figure(figsize=(8, 6))
plt.plot([0, 1, 2, 3], [10, 9, 6, 1])
plt.xlabel('x')
plt.ylabel('y')
plt.title('Example')
plt.grid();
```

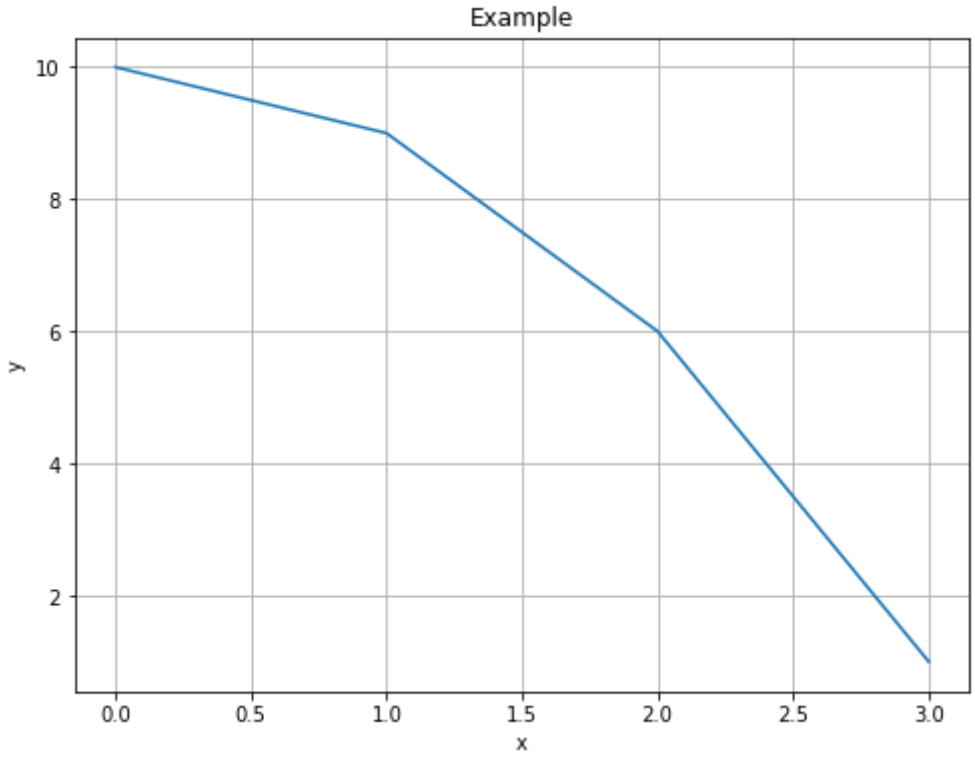

Виды графиков

Линейный график

In [5]:
```
# Готовим данные для графика в виде сводной таблицы

data = df.groupby('month')['job'].agg(count='count').reset_index().sort_values(by='m
data.head()
```

Out[5]:

	month	count
0	1	1403
1	2	2649
2	3	477
3	4	2932
4	5	13766

Matplotlib

In [6]:
```
plt.figure(figsize=(6, 4))

plt.plot(data['month'], data['count'])

plt.title('Динамика охвата рекламных кампаний')
plt.xlabel('Месяц')
plt.ylabel('Кол-во клиентов');
```

Seaborn

In [7]:
```
plt.figure(figsize=(6, 4))

sns.lineplot(x=data['month'], y=data['count'])

plt.title('Динамика охвата рекламных кампаний')
plt.xlabel('Месяц')
plt.ylabel('Кол-во клиентов');
```

Гистограмма

Matplotlib

In [8]:
```
plt.figure(figsize=(6, 4))

plt.hist(df['age'], bins=15)

plt.title('Возраст клиентов банка')
plt.xlabel('Интервал, лет')
plt.ylabel('Кол-во клиентов')
```

Out[8]:
```
Text(0, 0.5, 'Кол-во клиентов')
```

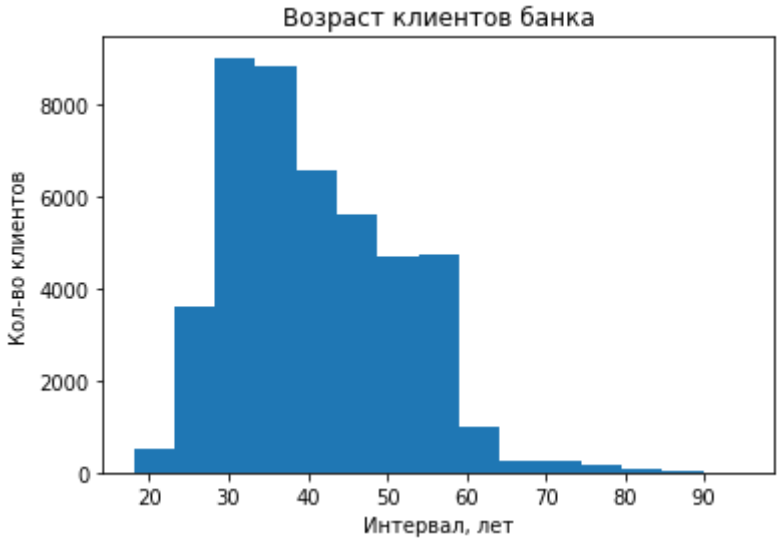

Seaborn

In [9]:
```
plt.figure(figsize=(6, 4))

sns.histplot(df['age'], bins=15)

plt.title('Возраст клиентов банка')
plt.xlabel('Интервал, лет')
plt.ylabel('Кол-во клиентов');
```

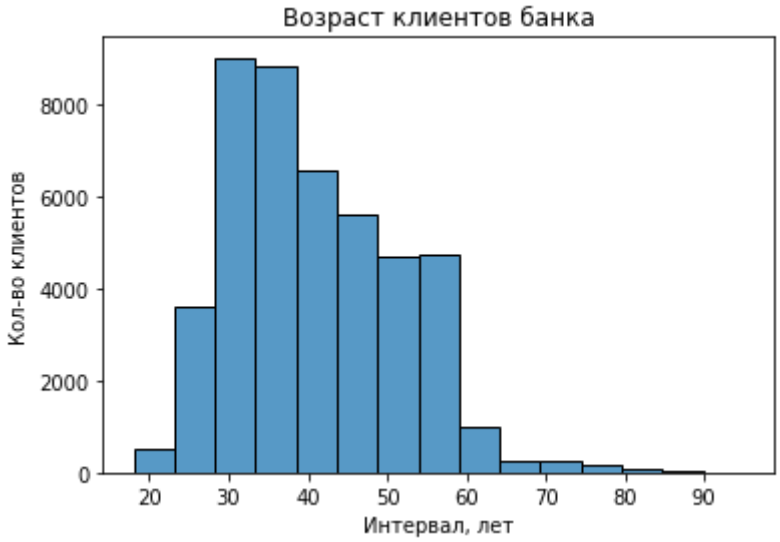

Диаграмма рассеяния

In [10]:
```
# Готовим данные для графика в виде сводной таблицы
data = df.groupby('age')['convert'].sum().reset_index()
data.head()
```

Out[10]:

	age	convert
0	18	7
1	19	11
2	20	15
3	21	22
4	22	40

Matplotlib

In [11]:
```
plt.figure(figsize=(6, 4))

plt.scatter(data['age'], data['convert'])

plt.title('График разброса значений')
plt.xlabel('Возраст')
plt.ylabel('Покупки');
```

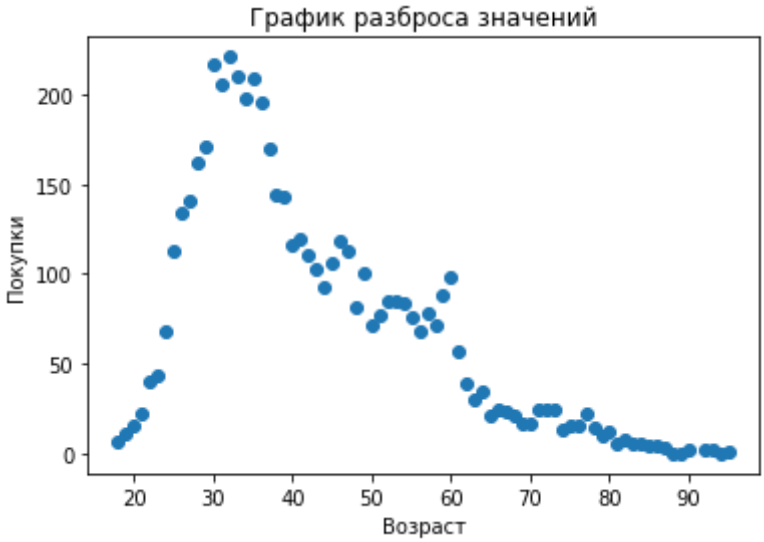

Seaborn

In [12]:
```
plt.figure(figsize=(6, 4))

sns.scatterplot(x=data['age'], y=data['convert'])

plt.title('График разброса значений')
plt.xlabel('Возраст')
plt.ylabel('Покупки');
```

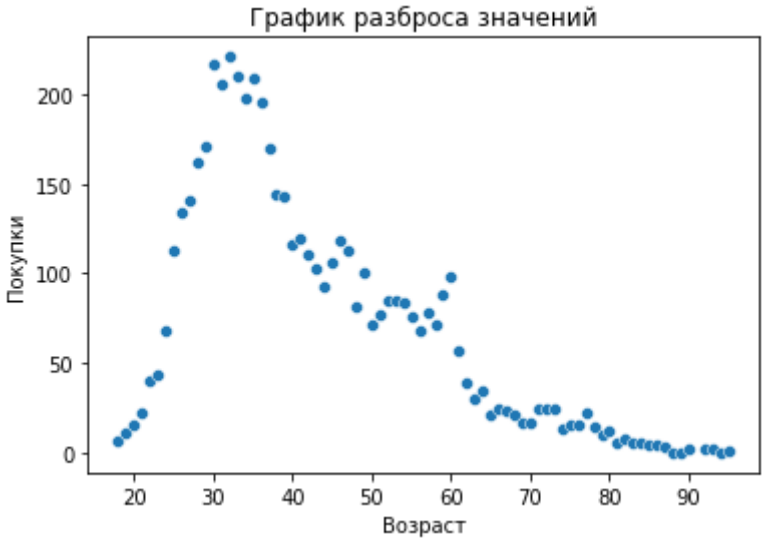

Столбчатые диаграммы

In [13]:
```
# Готовим данные для графика
data = df['job'].value_counts().reset_index()
data.head()
```

Out[13]:

	index	job
0	blue-collar	9732
1	management	9458
2	technician	7597
3	admin.	5171
4	services	4154

Matplotlib

In [15]:
```
plt.figure(figsize=(6, 4))

plt.bar(data['index'], data['job'])

plt.title('Род занятий клиентов банка')
plt.xlabel('Род занятий')
plt.ylabel('Кол-во')
plt.xticks(rotation=30);
```

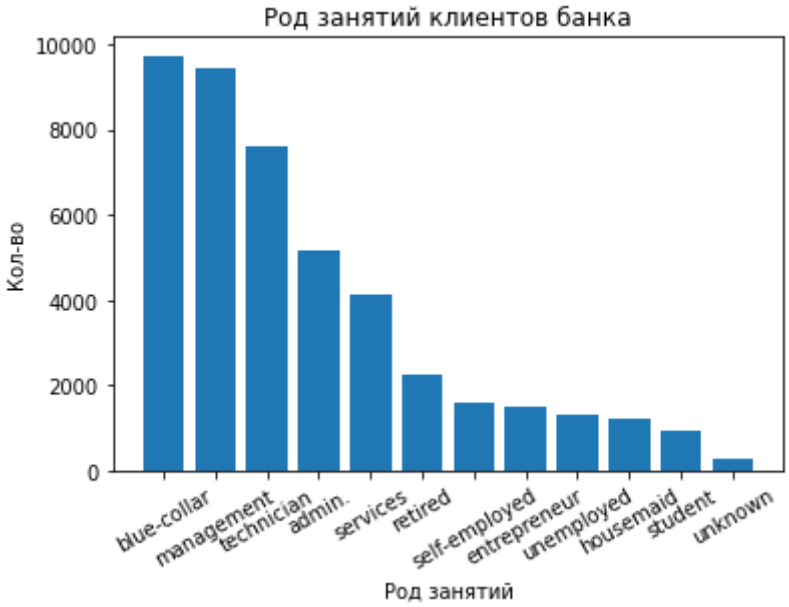

Seaborn

In [15]:
```
plt.figure(figsize=(6, 4))

sns.barplot(x=data['index'], y=data['job'])

plt.title('Род занятий клиентов банка')
plt.xlabel('Род занятий')
plt.ylabel('Кол-во')
plt.xticks(rotation=30);
```

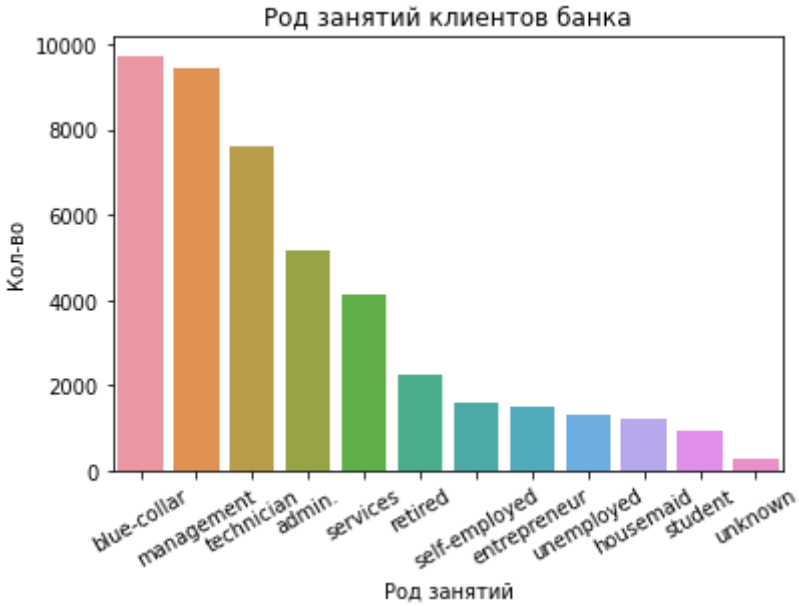

Многорядовые столбчатые диаграммы

In [16]:
```
# Готовим данные для графика
data = pd.crosstab(df['job'], df['convert']).reset_index().sort_values(by=0, ascendi
data.rename(columns={0: 'no', 1: 'yes'}, inplace=True)
data.head()
```

Out[16]:

convert	job	no	yes
1	blue-collar	9024	708
4	management	8157	1301
9	technician	6757	840
0	admin.	4540	631
7	services	3785	369

In [17]:

```
# Строим столбчатую многорядную диаграмму

plt.figure(figsize=(8, 6))

# определяем кол-во делений
n_ticks = np.arange(len(data['no']))

# определяем сдвиг
offset = 0.2

# определяем ширину столбцов
w = 0.4

# добавляем сдвиг к кол-ву делений
plt.bar(n_ticks - offset, data['no'], width=w)
plt.bar(n_ticks + offset, data['yes'], width=w)

plt.title('Род занятий клиентов банка, открывших депозит')
plt.xlabel('Род занятий')
plt.ylabel('Кол-во')
plt.legend(['no', 'yes'])
plt.xticks(n_ticks, data['job'], rotation = 30);  # добавляем метки делений
```

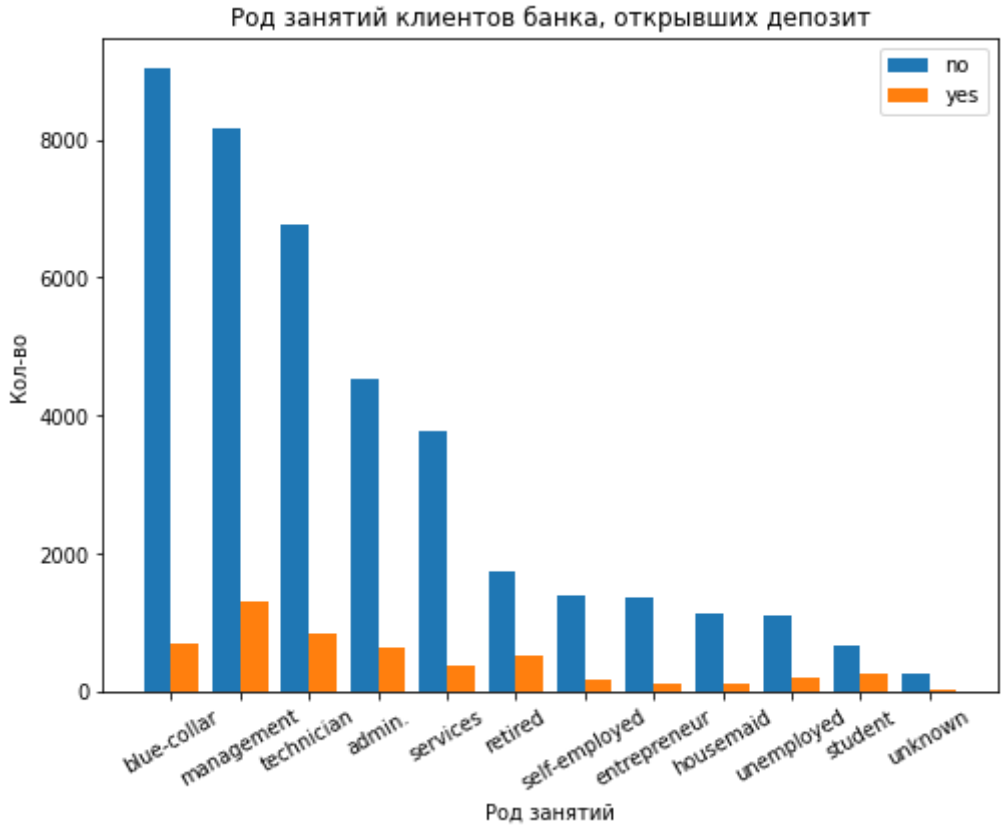

Сложенная столбчатая диаграмма

In [18]:
```
# Готовим данные для графика
data = pd.crosstab(df['job'], df['convert'], normalize='index').reset_index().sort_v
data.rename(columns={0: 'no', 1: 'yes'}, inplace=True)
data.head()
```

Out[18]:

convert	job	no	yes
1	blue-collar	0.927250	0.072750
2	entrepreneur	0.917283	0.082717
3	housemaid	0.912097	0.087903
7	services	0.911170	0.088830
9	technician	0.889430	0.110570

In [19]:
```
# Строим столбчатую многорядную сложенную диаграмму

plt.figure(figsize=(8, 6))

plt.bar(data['job'], data['no'])
plt.bar(data['job'], data['yes'], bottom=data['no'])

plt.title('Род занятий клиентов банка, открывших депозит')
plt.xlabel('Род занятий')
plt.ylabel('Доля клиентов')
plt.legend(['no', 'yes'])
plt.xticks(rotation = 30);
```

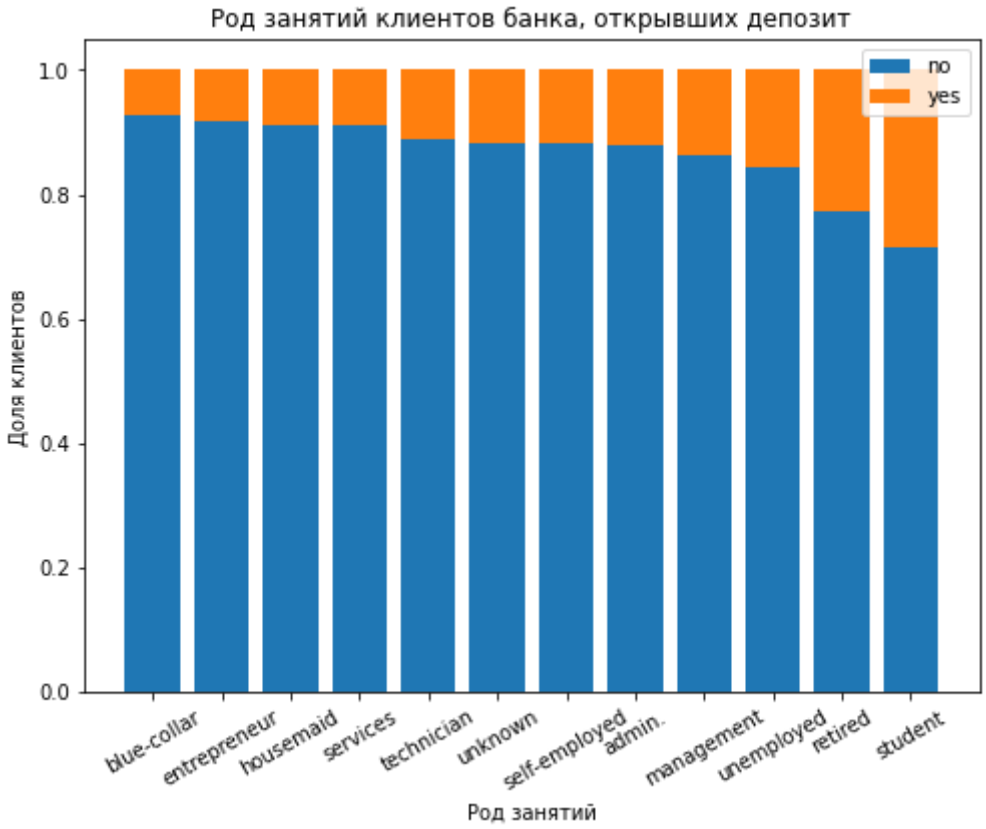

Ящики с усами

In [20]:
```
# Готовим данные для графика
data1 = df['duration'][df['convert'] == 1]
data2 = df['duration'][df['convert'] == 0]
data1.head()
```

Out[20]:
```
83     1042
86     1467
87     1389
129     579
168     673
Name: duration, dtype: int64
```

In [21]:
```
plt.figure(figsize=(6, 4))

sns.boxplot(data=[data1]);
```

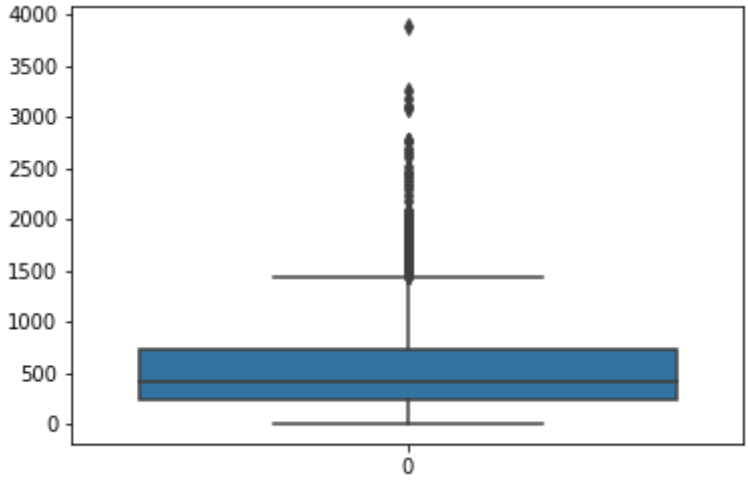

In [22]:
```
sns.histplot(x=data1);
```

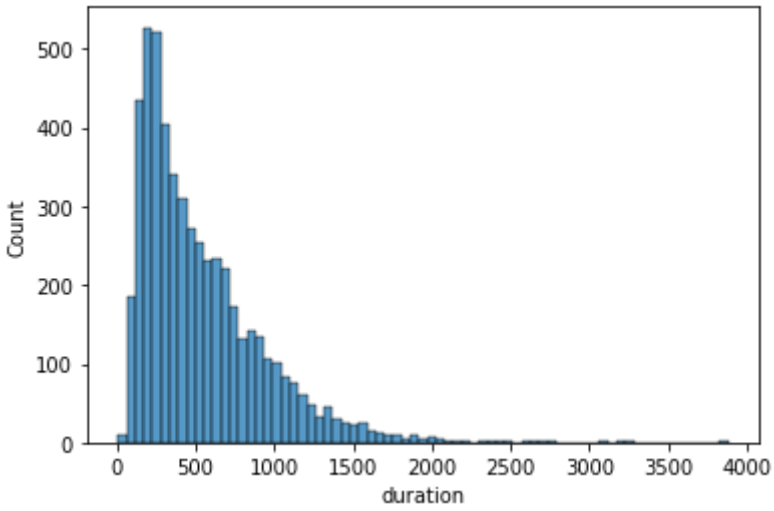

Matplotlib

In [23]:
```
# Строим боксплот

plt.figure(figsize=(6, 4))

plt.boxplot([data1, data2])

plt.title('Время последнего контакта')
plt.xlabel('Совершили покупку')
plt.ylabel('Время в секундах')
plt.xticks([1, 2], ['yes', 'no']);
```

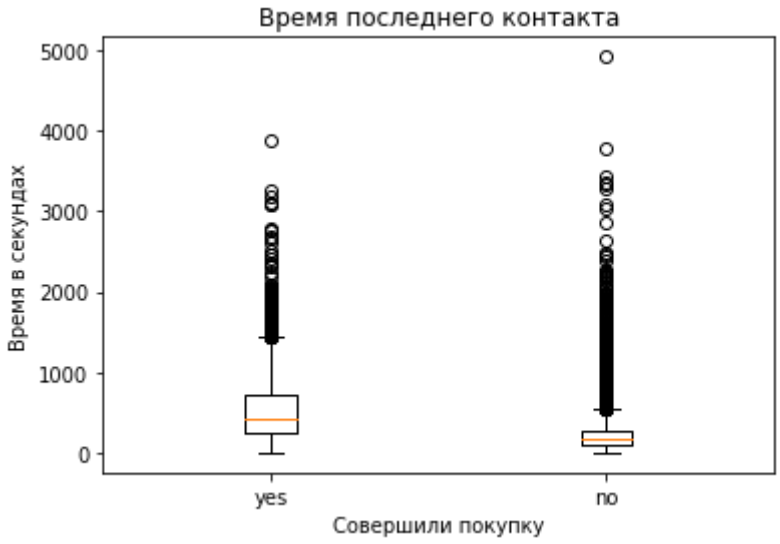

In [24]:
```
# Строим боксплот без выбросов

plt.figure(figsize=(6, 4))

plt.boxplot([data1, data2], showfliers=False)

plt.title('Время последнего контакта')
plt.xlabel('Совершили покупку')

plt.ylabel('Время в секундах')
plt.xticks([1, 2], ['yes', 'no']);
```

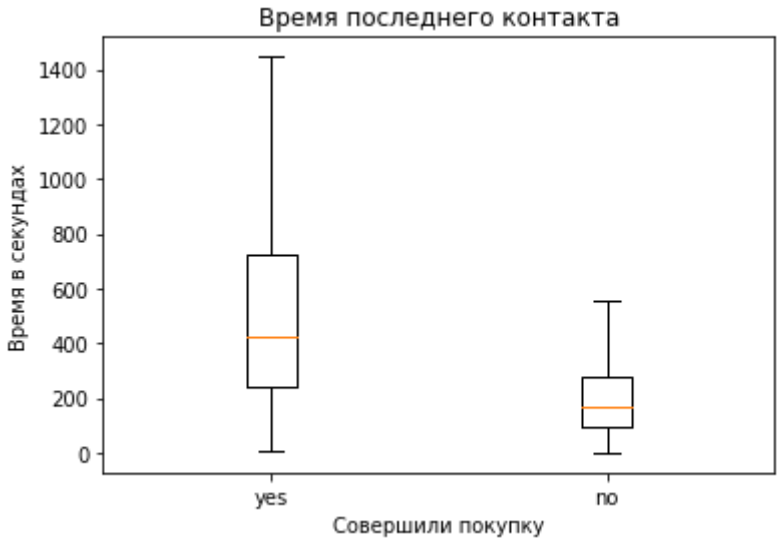

Seaborn

In [25]:
```
# Строим боксплот без выбросов

plt.figure(figsize=(6, 4))

sns.boxplot(data=[data1, data2], showfliers=False)

plt.title('Время последнего контакта')
plt.xlabel('Совершили покупку')

plt.ylabel('Время в секундах')
plt.xticks([0, 1], ['yes', 'no']);
```

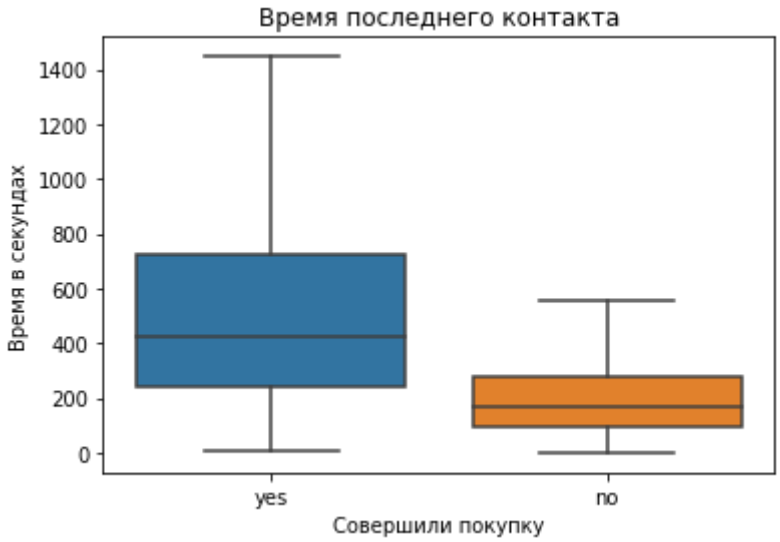

Круговая диаграмма

In [26]:
```
# Готовим данные для графика
data = df['convert'].value_counts()
data.index = ['no', 'yes']
data.head()
```

Out[26]:
```
no     39922
yes     5289
Name: convert, dtype: int64
```

Matplotlib

In [27]:
```
# Строим круговую диаграмму

plt.figure(figsize=(6, 4))

plt.pie(data, autopct='%1.1f%%')

plt.title('Доля клиентов банка, открывших депозит')
plt.legend(data.index);
```

Визуальный анализ данных

Описание датасета

Статистические данные о ряде домов в Калифорнии, основанные на переписи 1990 года.

- **longitude** - долгота
- **latitude** - широта
- **housing_median_age** - средний возраст дома
- **total_rooms** - общее количество комнат
- **total_bedrooms** - общее количество спален
- **population** - количество проживающих
- **households** - домохозяйства
- **ocean_proximity** - близость океана
- **median_income** - средний доход
- **median_house_value** - средняя стоимость дома

In [28]:
```
df = pd.read_csv('housing.csv', sep=';')
df.head()
```

Out[28]:

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	median_incom
0	-122.23	37.88	41.0	880.0	129.0	322.0	8.32
1	-122.22	37.86	21.0	7099.0	1106.0	2401.0	8.30
2	-122.24	37.85	52.0	1467.0	190.0	496.0	7.25
3	-122.25	37.85	52.0	1274.0	235.0	558.0	5.64
4	-122.25	37.85	52.0	1627.0	280.0	565.0	3.84

Распределение вещественных признаков

In [29]:
```
# {'red', 'green', 'blue'} - дискретный признак ('red', 'green', 'blue', 'red', 'gre
# [0, 100] - вещественный признак (0, 5, 5.6, 10.5, 10.57)
```

In [30]:
```
plt.figure(figsize=(8, 6))
plt.hist(df['median_house_value'])
plt.title('Распределение median house value')
plt.xlabel('Стоимость')
plt.ylabel('Количество');
```

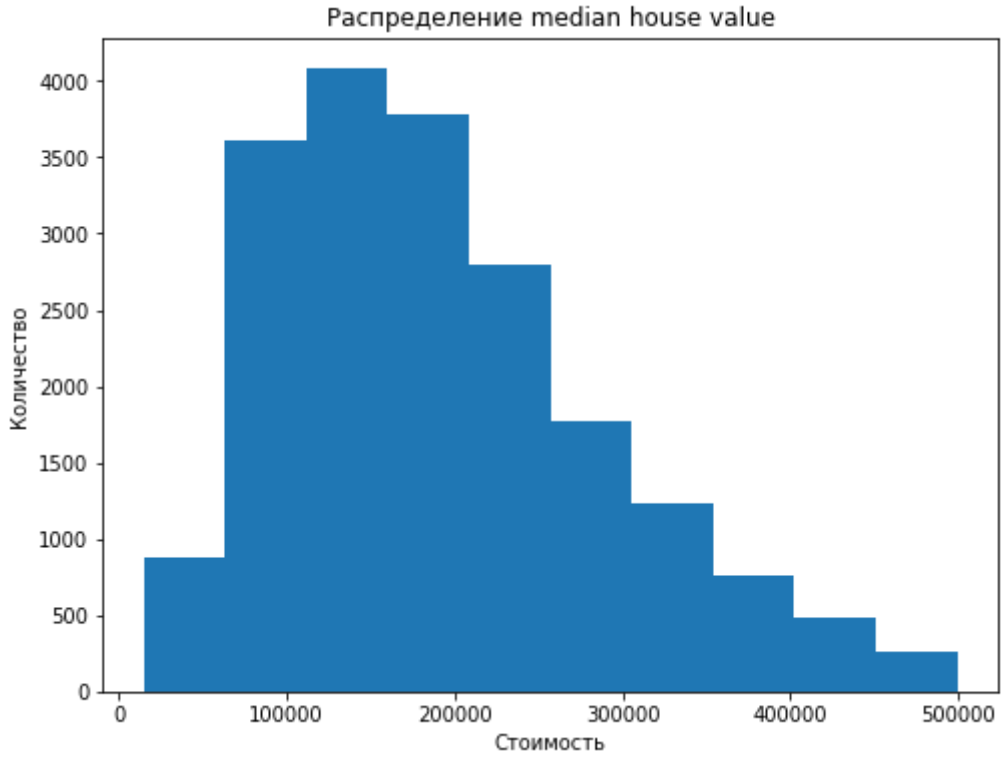

In [31]:
```
df_num_features = df.select_dtypes(include=['float64', 'float32', 'float16'])
df_num_features.drop('median_house_value', axis=1, inplace=True)
```

In [32]:
```
df_num_features.hist(figsize=(16, 16), bins=20, grid=False);
```

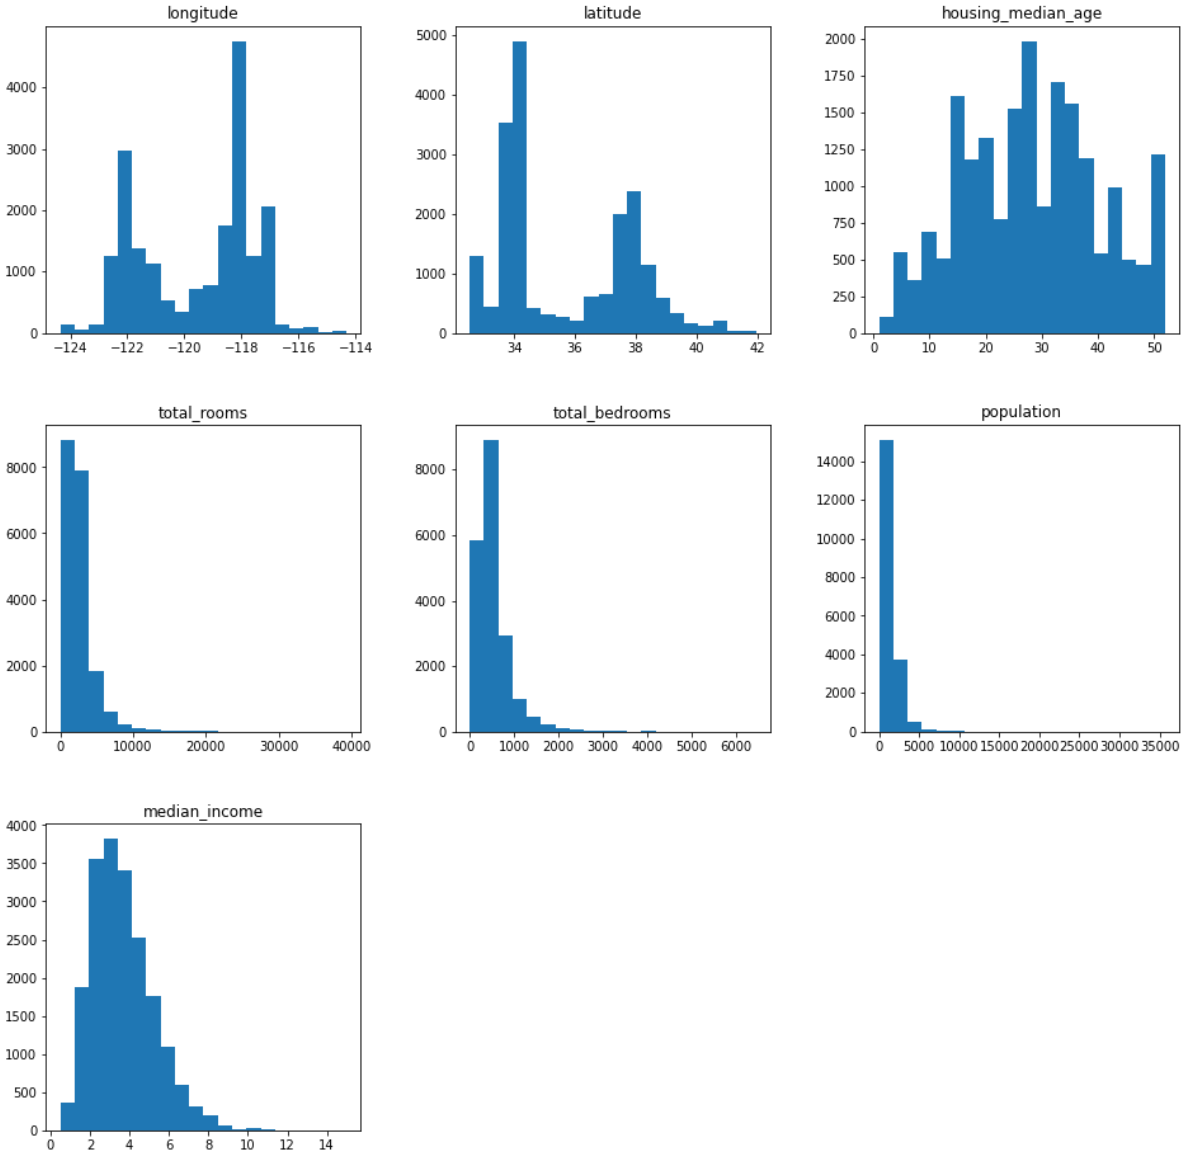

Поиск выбросов с помощью box plot

Как строится box plot

Подробное объяснение

- box - от 25% до 75% квантиля
- линия в середине box - медиана
- "усы"

Как строятся "усы" - вариантов масса

- среднее +/- 3 сигма (стандартное отклонение)
- min / max
- median +/- 1.5*(q75 - q25),
- ...

*Интерквартильный размах = q75 - q25

In [33]:
```
plt.figure(figsize=(6, 3))

sns.boxplot(x=df['population'], whis=1.5)
```

```
plt.xlabel('population')
plt.show()
```

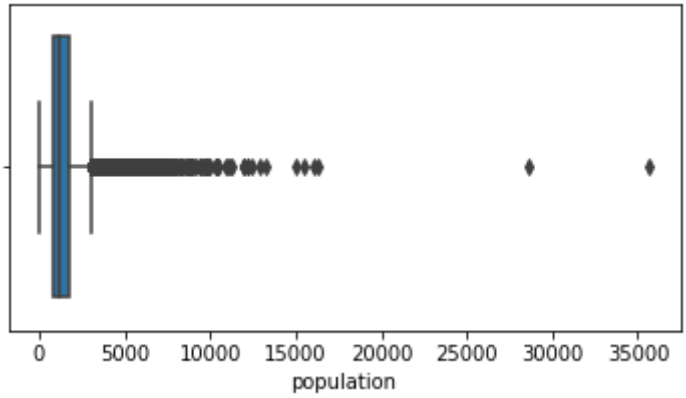

Анализ категориальных признаков

In [34]:
```
counts = df['ocean_proximity'].value_counts()

plt.figure(figsize=(8, 6))
plt.title('ocean_proximity')
sns.barplot(x=counts.index, y=counts.values)

plt.show()
```

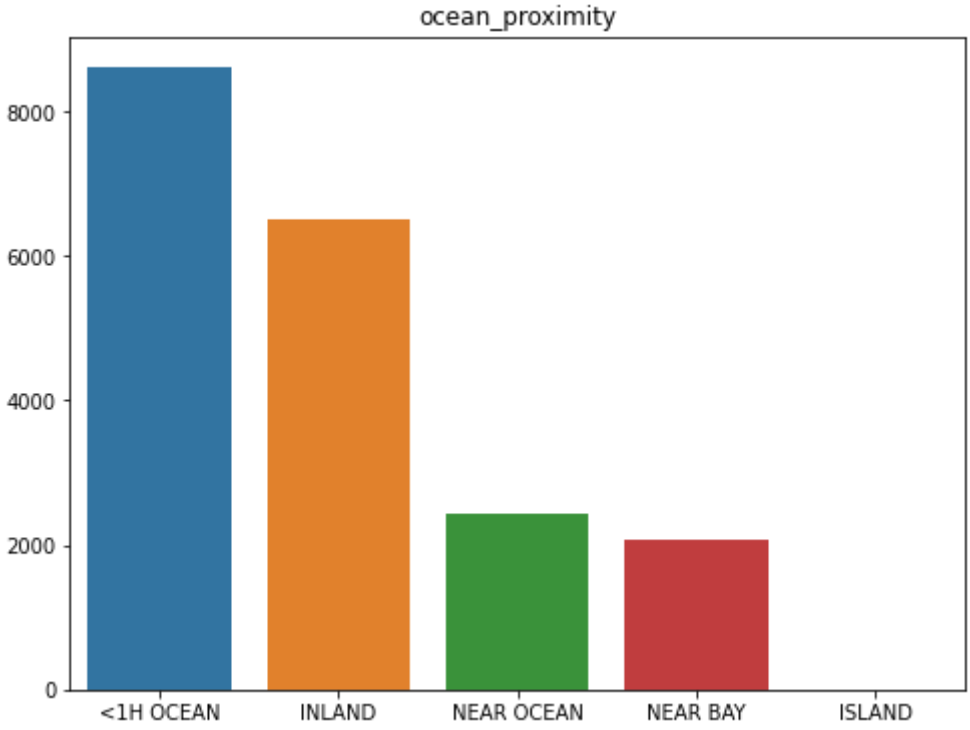

In [35]:
```
counts = df['INLAND'].value_counts()

plt.figure(figsize=(8, 6))
plt.title('INLAND')
sns.barplot(x=counts.index, y=counts.values)

plt.show()
```

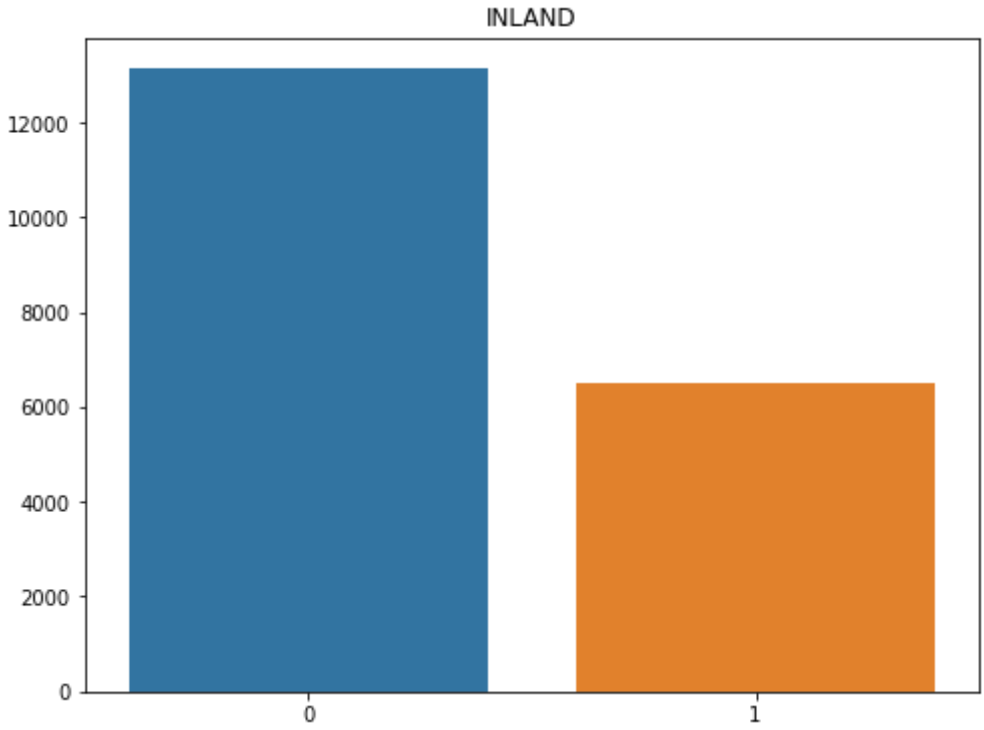

Анализ взаимных распределений

In [36]:
```
sns.jointplot(x=df['median_income'], y=df['median_house_value'], kind='reg');
```

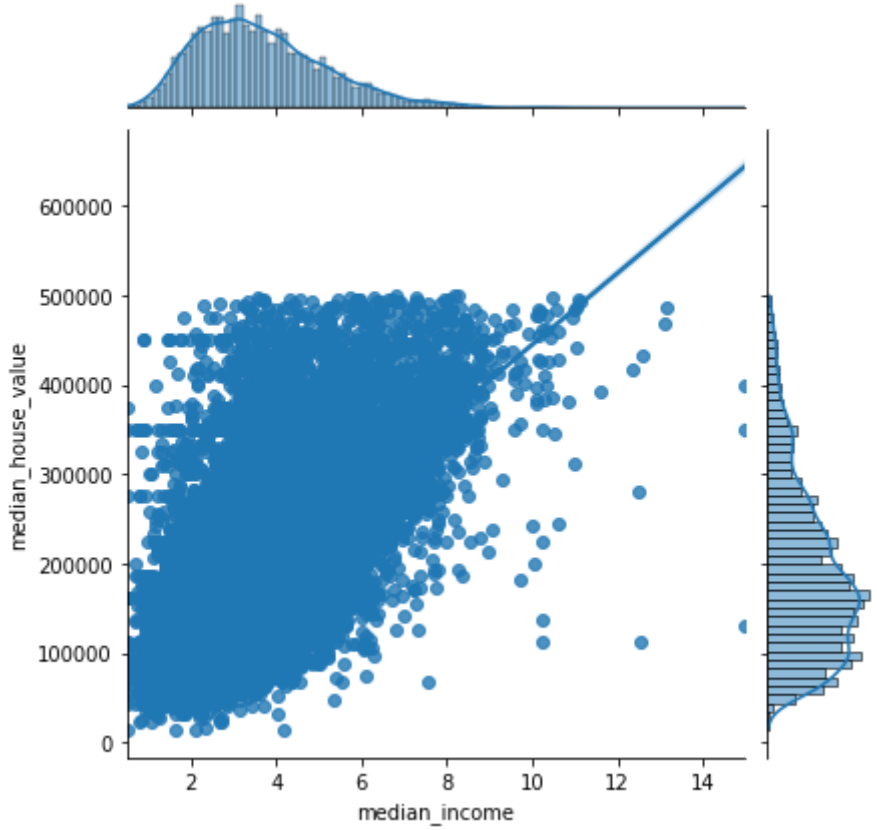

In [37]:
```
sns.jointplot(x=df['latitude'], y=df['longitude'], kind='kde');
```

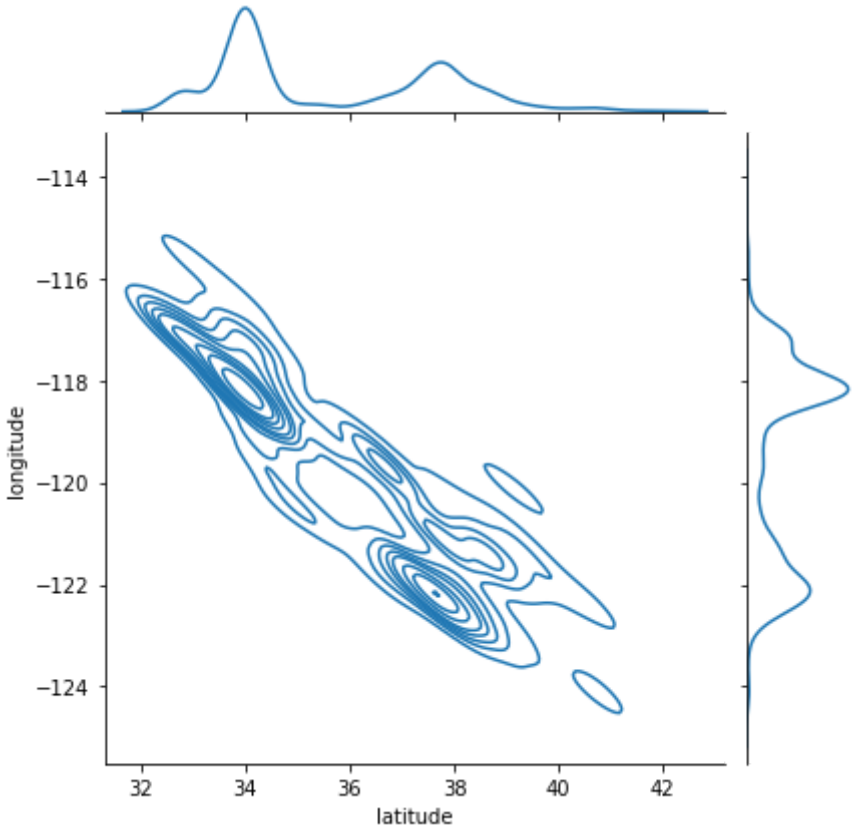

In [38]:
```
sns.jointplot(x=df['latitude'], y=df['median_house_value'], kind='reg');
```

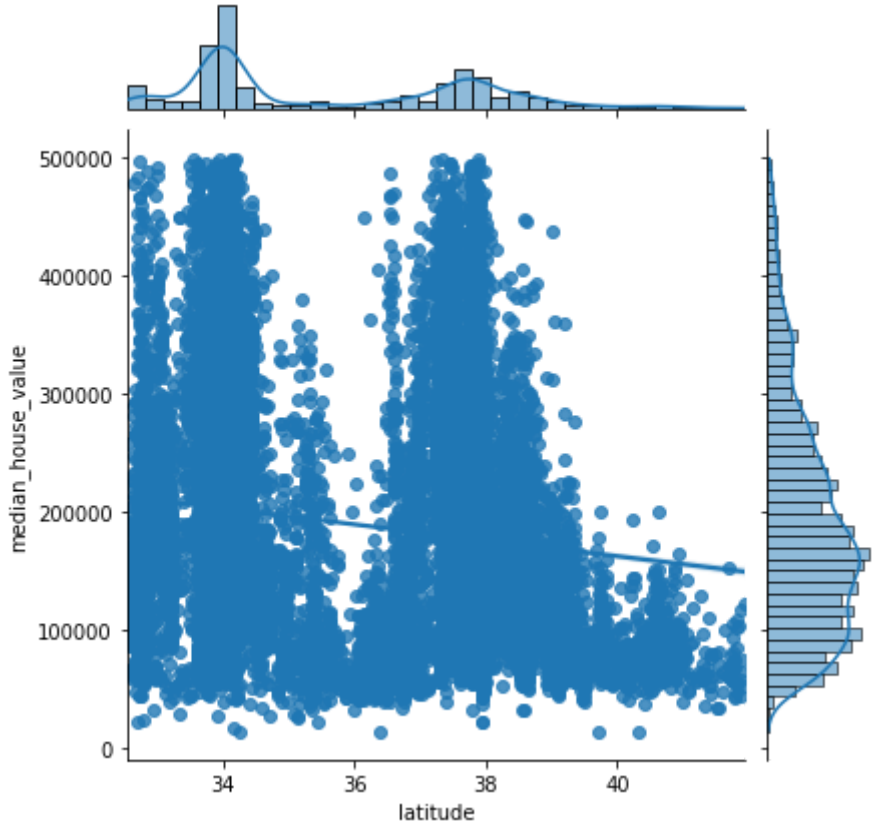

Видно два города, имеет смысл посмотреть на зависимость по отдельности

In [39]:
```
df_cut = df[df['latitude'] < 36]
sns.jointplot(x=df_cut['latitude'], y=df_cut['median_house_value'], kind='reg');
```

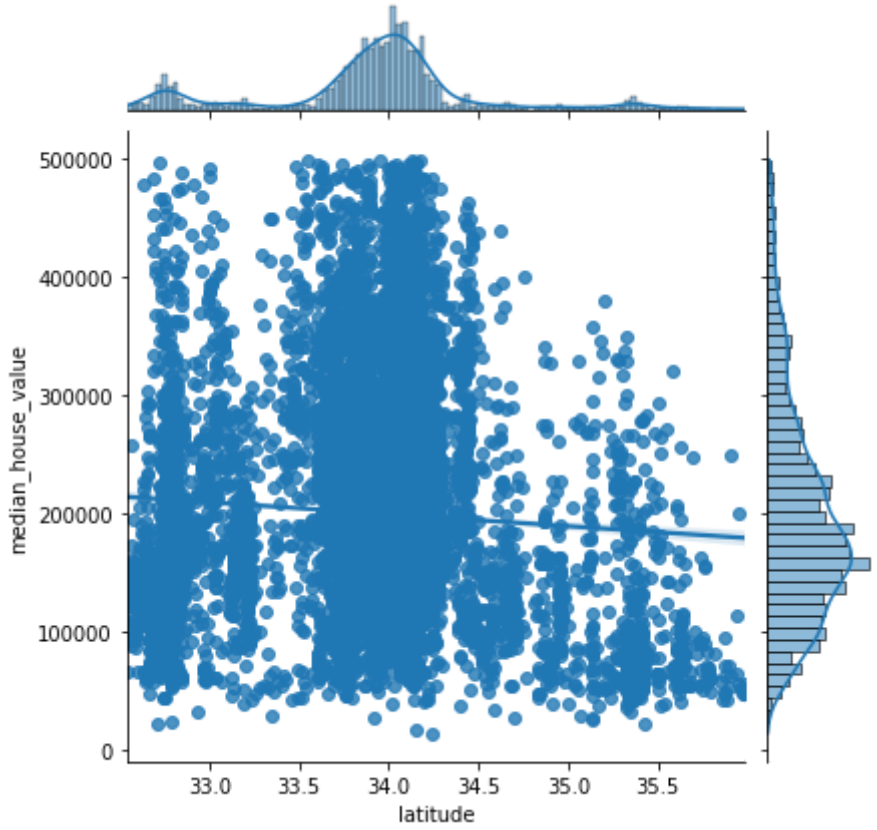

In [40]:
```
df_cut = df[df['latitude'] >= 36]
sns.jointplot(x=df_cut['latitude'], y=df_cut['median_house_value'], kind='reg');
```

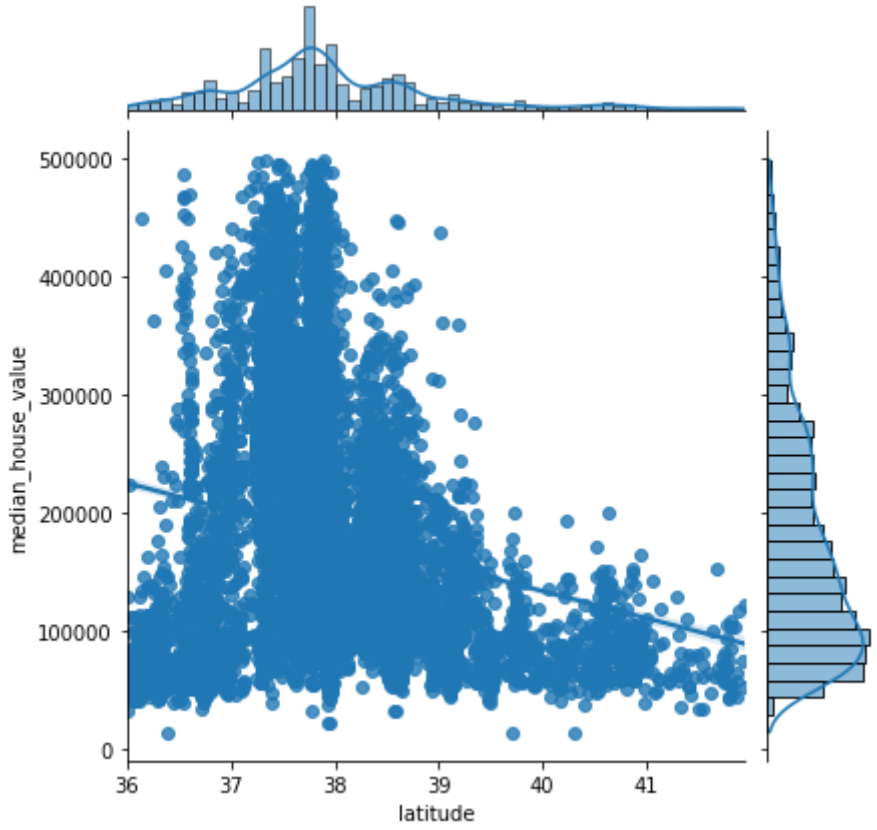

longitude

In [41]:
```
sns.jointplot(x=df['longitude'], y=df['median_house_value'], kind='reg');
```

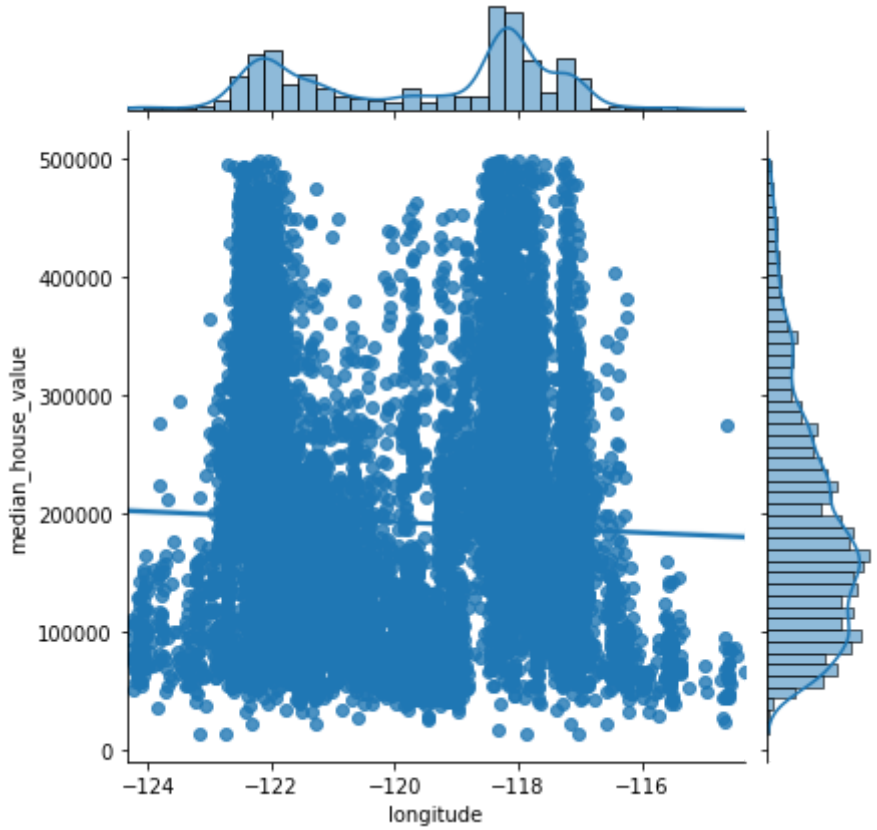

In [42]:
```
df_cut = df[df['longitude'] < -120]
sns.jointplot(x=df_cut['longitude'], y=df_cut['median_house_value'], kind='reg');
```

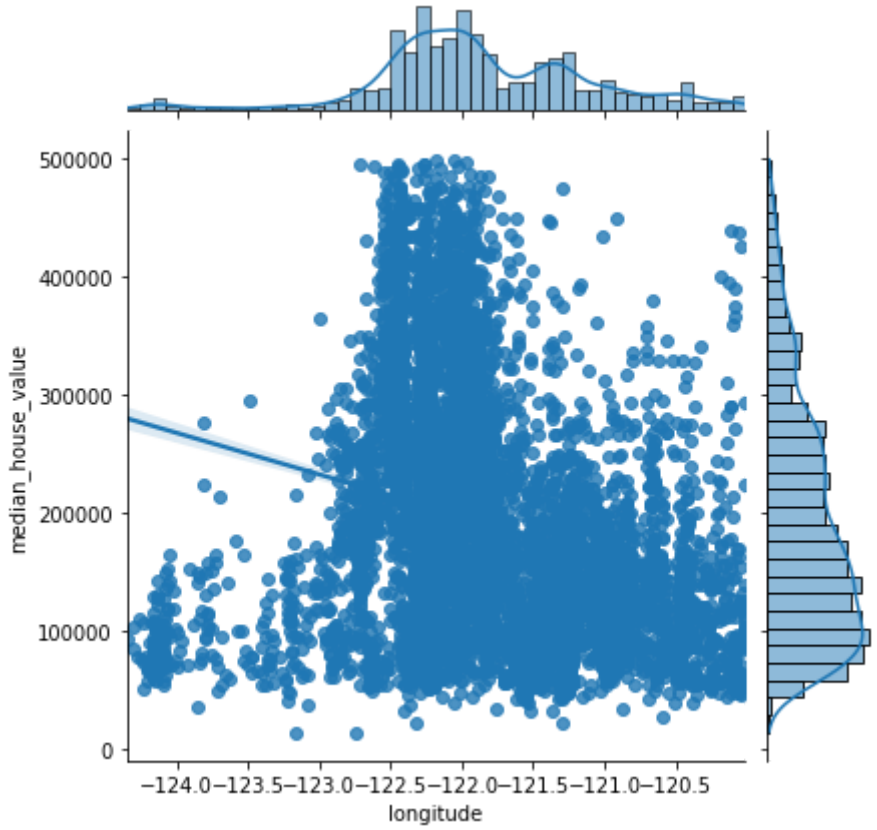

In [43]:
```
df_cut = df[df['longitude'] >= -120]
sns.jointplot(x=df_cut['longitude'], y=df_cut['median_house_value'], kind='reg');
```

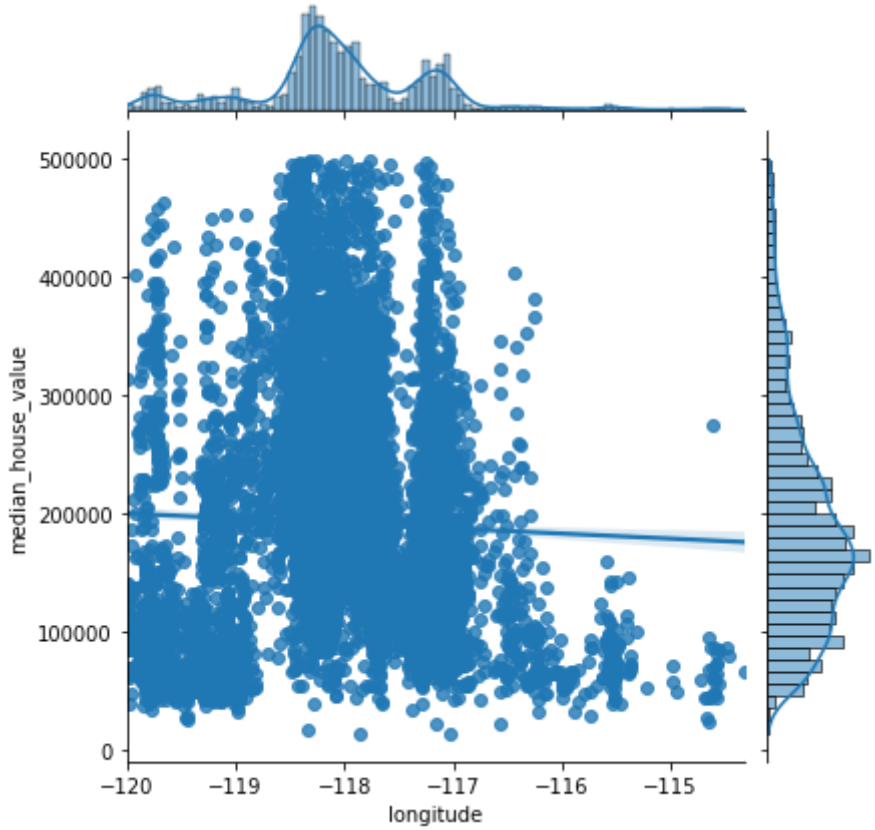

Категориальные / бинарные признаки

box plot

In [44]:
```
plt.figure(figsize=(16, 8))

sns.boxplot(x=df['median_house_value'], y=df['ocean_proximity'], whis=1.5)

plt.xlabel('median_house_value')
plt.ylabel('ocean_proximity')
plt.title('Distribution of median_house_value by ocean_proximity');
```

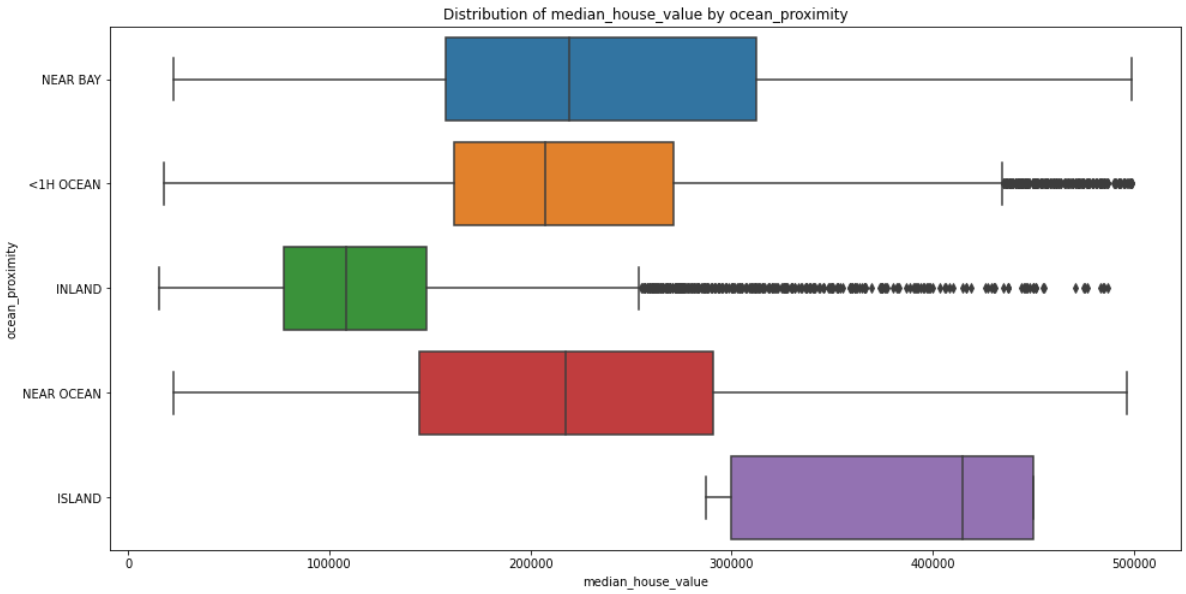

Как строится box plot

Подробное объяснение

- box - от 25% до 75% квантиля
- линия в середине box - медиана
- "усы"

Как строятся "усы" - вариантов масса

- среднее +/- 3 сигма (стандартное отклонение)
- min / max
- median +/- 1.5*(q75 - q25),
- ...

*Интерквартильный размах = q75 - q25

Матрица корреляций

- Показывает линейную связь между переменными
- Изменяется от -1 до 1
- Корреляция - мера только **линейной** связи

In [52]:
```
sns.jointplot(x=df['total_rooms'], y=df['total_bedrooms'], kind='reg');
```

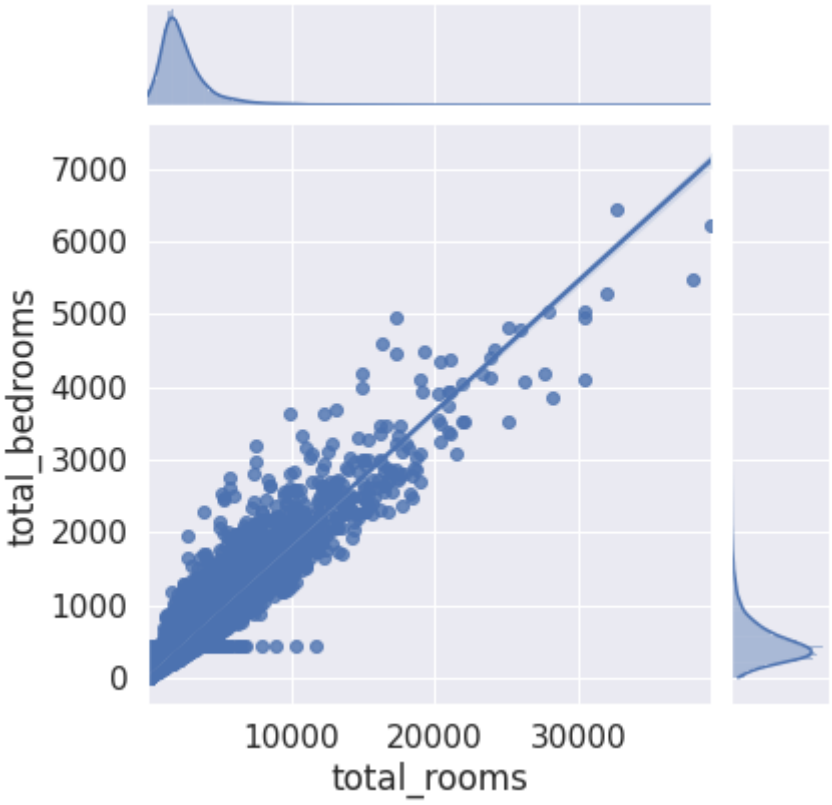

In [53]:
```
sns.jointplot(x=df['longitude'], y=df['latitude'], kind='reg');
```

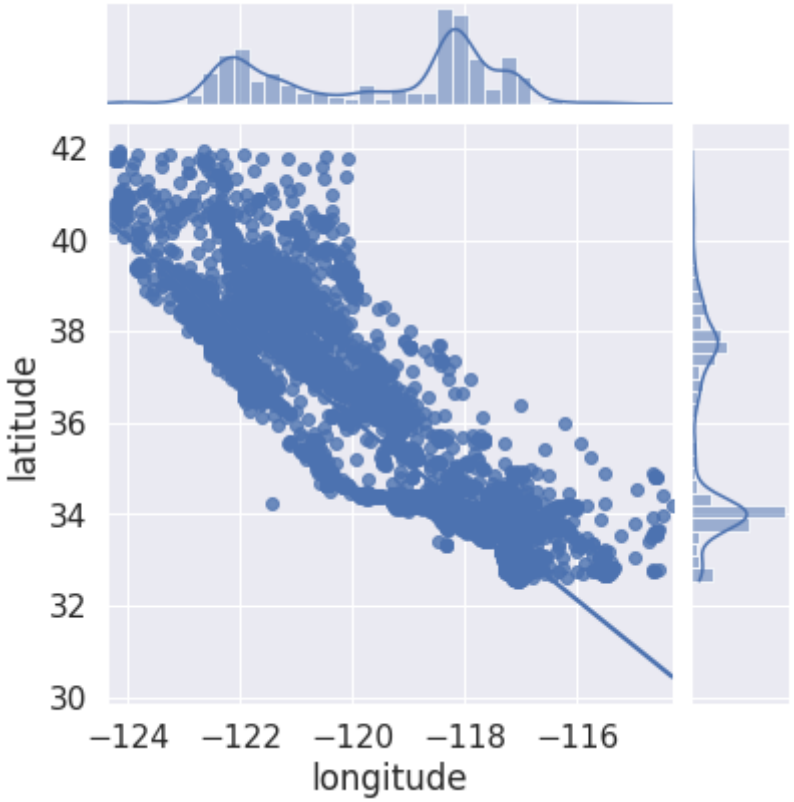

In [51]:
```
corr_matrix = df.corr()
corr_matrix = np.round(corr_matrix, 1)
corr_matrix[np.abs(corr_matrix) < 0.3] = 0
corr_matrix
```

Out[51]:

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	populat
longitude	1.0	-0.9	0.0	0.0	0.0	
latitude	-0.9	1.0	0.0	0.0	0.0	
housing_median_age	0.0	0.0	1.0	-0.4	-0.3	
total_rooms	0.0	0.0	-0.4	1.0	0.9	
total_bedrooms	0.0	0.0	-0.3	0.9	1.0	
population	0.0	0.0	-0.3	0.8	0.9	
median_income	0.0	0.0	0.0	0.0	0.0	
median_house_value	0.0	0.0	0.0	0.0	0.0	
INLAND	0.0	0.4	0.0	0.0	0.0	

In [54]:
```
plt.figure(figsize=(10, 8))

sns.set(font_scale=1.4)

sns.heatmap(corr_matrix, annot=True, linewidths=.5, cmap='coolwarm')

plt.title('Correlation matrix');
```

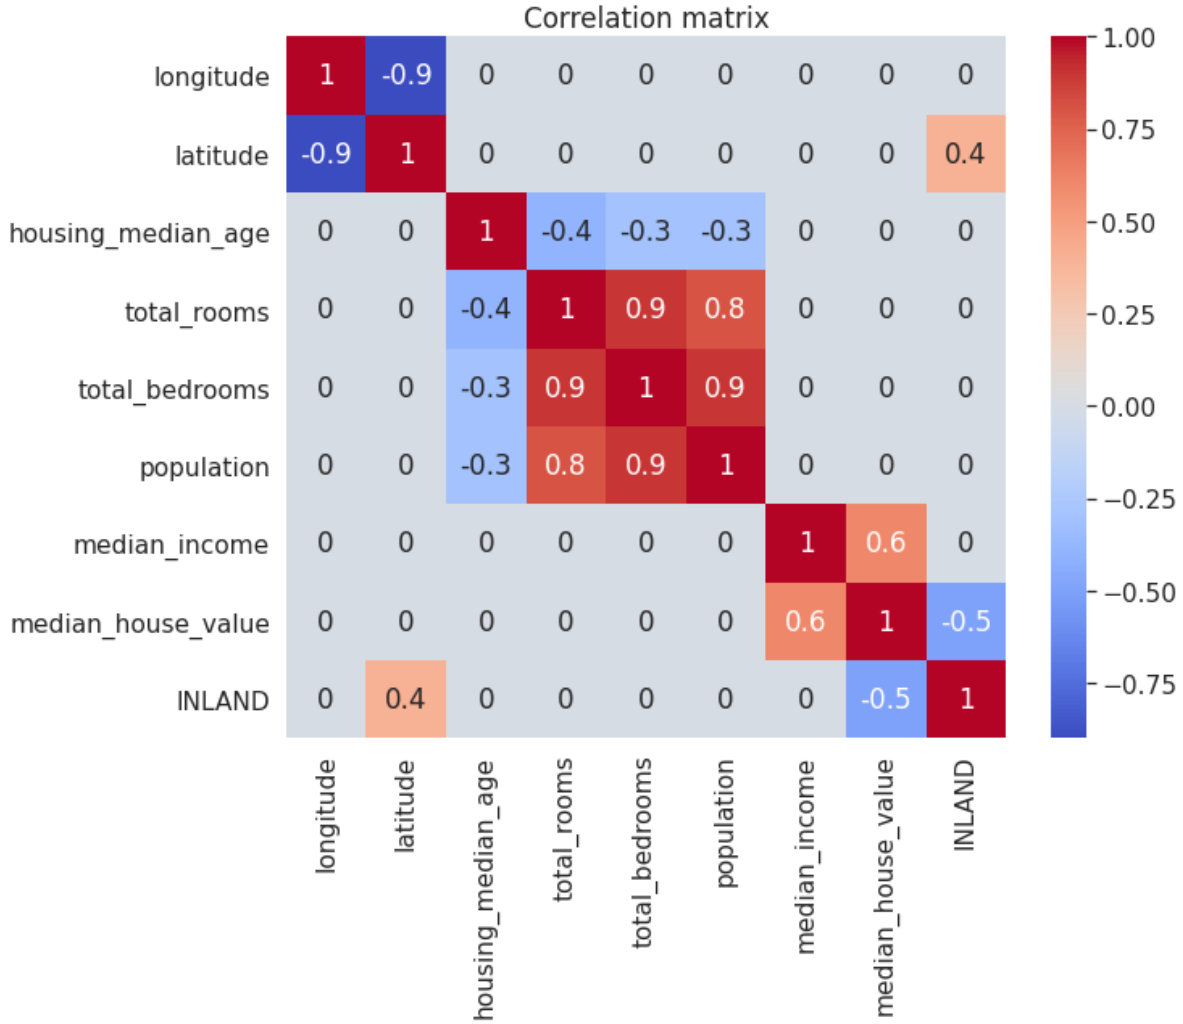

Гео данные

In [72]:
```
min_long = -124.55
max_long = -113.80

min_lat = 32.45
max_lat = 42.05
```

In [73]:
```
import matplotlib.image as img
california_map = img.imread('California_Map.png')

plt.figure(figsize=(12, 9))
plt.imshow(california_map,
           extent=[min_long, max_long, min_lat, max_lat], alpha=0.5);
```

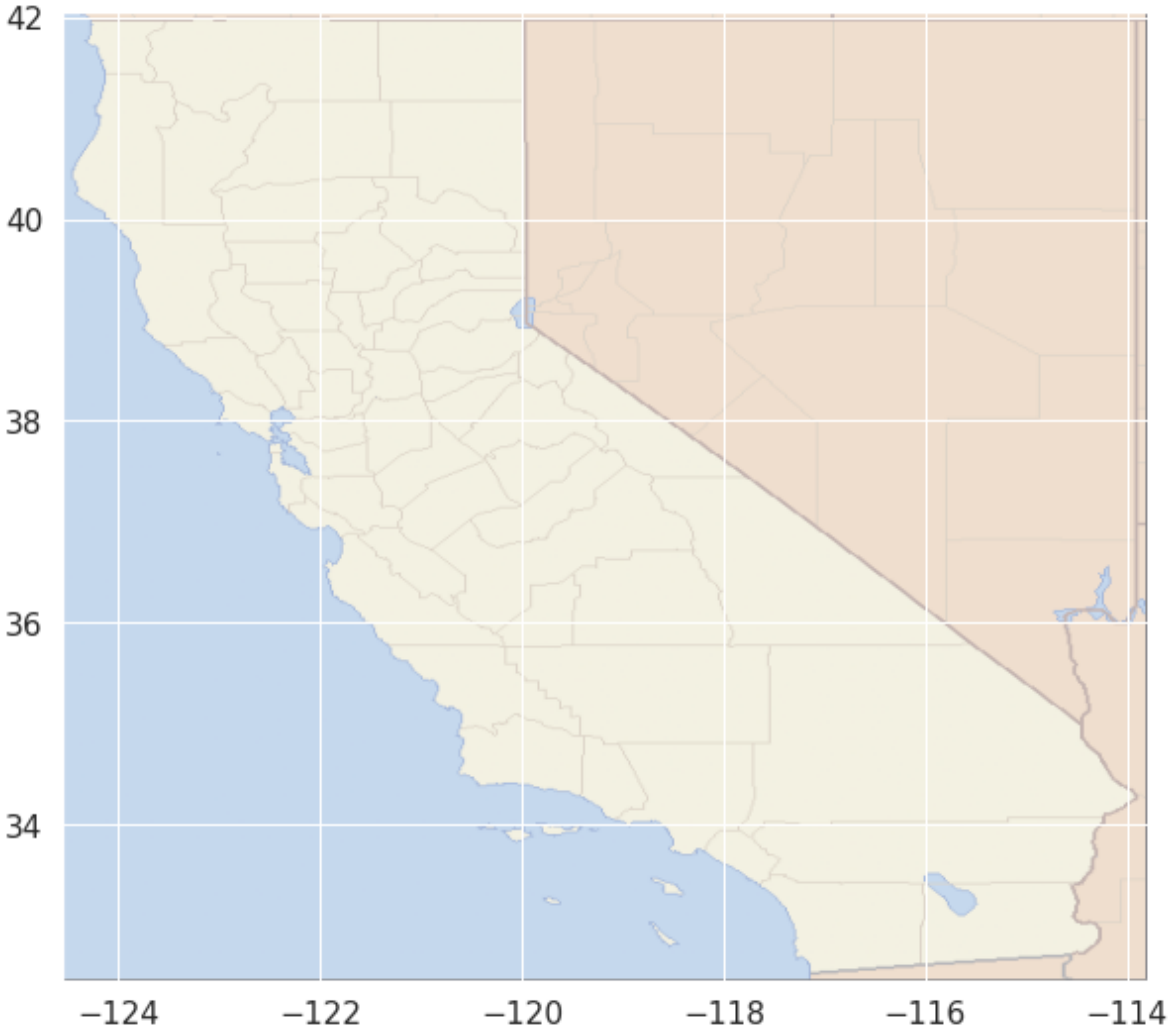

In [78]:
```
plt.figure(figsize=(12, 9))

sc = plt.scatter(df['longitude'], df['latitude'], alpha=0.5, c=df['median_house_valu

plt.imshow(california_map,
           extent=[min_long, max_long, min_lat, max_lat], alpha=0.5)

plt.colorbar(sc)
plt.xlabel("Longitude")
plt.ylabel("Latitude")
plt.title("Homes geography");
```

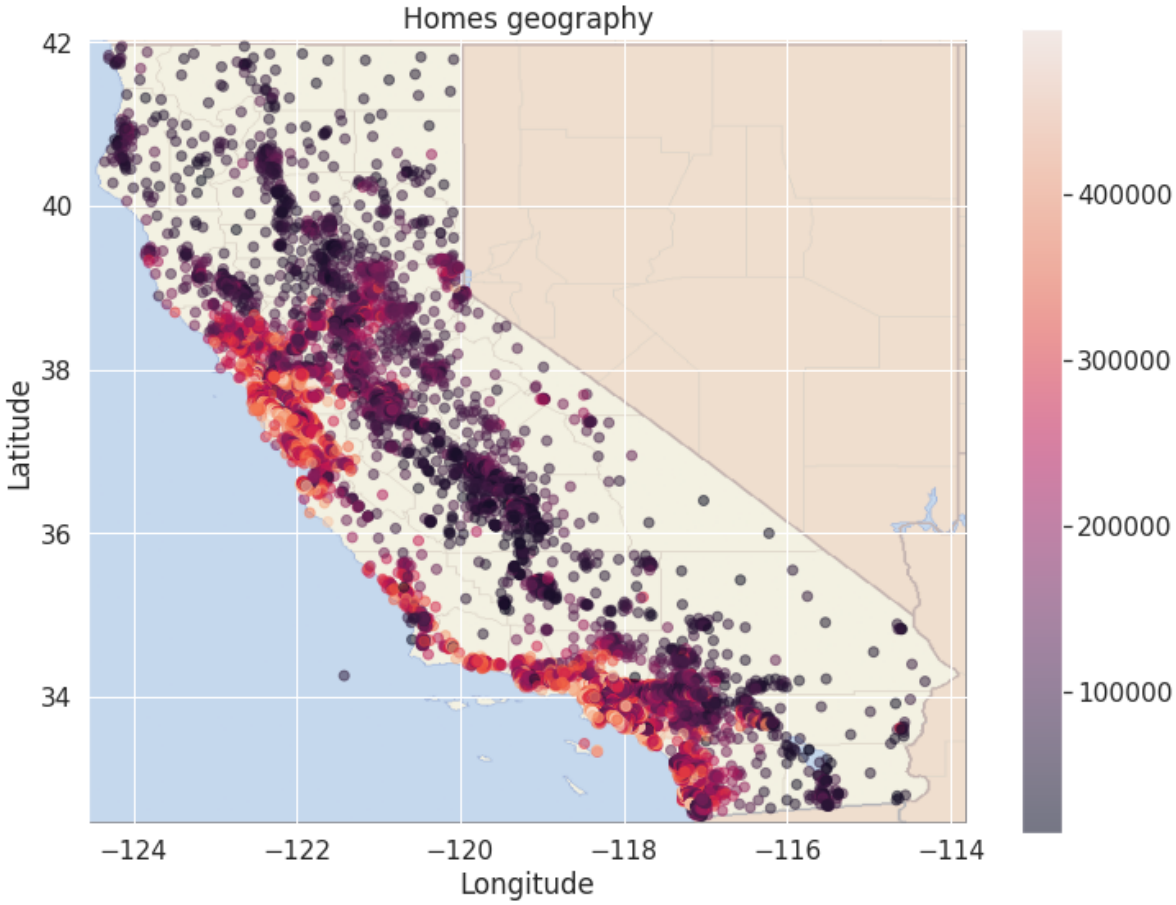

Folium

In [84]:
```
# !pip install folium
```

In [85]:
```
import folium
this_map = folium.Map(prefer_canvas=True)

def plotDot(point):
    folium.CircleMarker(
        location=[point.latitude, point.longitude],
        radius=2,
        popup=point.median_house_value
    ).add_to(this_map)

df.apply(plotDot, axis=1)

this_map.fit_bounds(this_map.get_bounds())

this_map
```

Out[85]: Make this Notebook Trusted to load map: File -> Trust Notebook